PROGRAMOWANIE V

Projekt 2. Studio jakości i wizualizacji danych

Laboratoria 6–9 | Pandas, Matplotlib, Seaborn i GUI

Forma	projekt aplikacyjny
Technologia bazowa	Python 3 + Tkinter/ttk
Punktacja	100 pkt
Wersja dokumentu	5 października 2026

Dokument dla studentów i arkusz oceny dla prowadzącego.

Cel i scenariusz

Zaprojektuj aplikację, która prowadzi użytkownika od wczytania pliku CSV przez diagnozę i czyszczenie danych aż do interaktywnej wizualizacji i eksportu wyników. Użytkownik powinien widzieć, jakie operacje zmieniły zbiór, zamiast otrzymać jedynie „oczyszczony” plik bez uzasadnienia.

Wymagania funkcjonalne

- **Wczytywanie:** wybór CSV, obsługa co najmniej przecinka i średnika, kontrolowany błąd kodowania lub wadliwego wiersza oraz podgląd danych.
- **Profil danych:** liczba rekordów i kolumn, typy, statystyki opisowe, liczba i procent braków, pełne duplikaty oraz liczba unikalnych wartości.
- **Reguły jakości:** możliwość wskazania zakresu poprawnych wartości dla co najmniej jednej kolumny; wykrywanie odstających wartości metodą IQR albo inną udokumentowaną metodą.
- **Czyszczenie:** usuwanie duplikatów; co najmniej dwie strategie braków (np. usunięcie i imputacja); obsługa wartości błędnych; oznaczenie albo obsługa outlierów.
- **Ślad zmian:** raport liczby rekordów dotkniętych każdą operacją; możliwość rozpoczęcia od danych surowych bez ponownego uruchamiania programu.
- **Wizualizacje:** histogram, wykres punktowy, pudełkowy i słupkowy; dobór kolumn zgodny z typem wykresu; tytuł i opis osi.
- **GUI i eksport:** wybór pliku, kolumn, operacji i rodzaju wykresu; podgląd wykresu w oknie; zapis oczyszczonego CSV oraz wykresu do PNG i co najmniej jednego z formatów PDF/SVG.

Zasady analizy

Aplikacja nie może automatycznie usuwać wszystkich odstających obserwacji bez pokazania reguły i liczby zmian. Wartość odstająca nie zawsze jest błędem; student powinien uzasadnić, kiedy ją oznacza, przycina, usuwa albo pozostawia.

Harmonogram i kamienie milowe

Zajęcia	Zakres pracy	Rezultat do pokazania	Kryterium zaliczenia etapu
Lab. 6	Pandas, profil danych, identyfikacja problemów i pipeline czyszczenia.	Skrypt/notebook tworzący raport przed/po i zapisujący cleaned.csv.	Raport wykrywa przygotowane problemy; operacje nie modyfikują niepowiązanych kolumn; wyniki są powtarzalne.
Lab. 7	Matplotlib i Seaborn; cztery typy wykresów; korelacja.	Zestaw wykresów dla danych przed/po oraz funkcja budująca wykres na podstawie parametrów.	Typy kolumn są walidowane; opisy osi i tytuły są czytelne; wnioski nie mylą korelacji z przyczynowością.
Lab. 8	Tkinter/ttk; stan sesji; wczytanie, profil i wybór parametrów.	GUI ładuje CSV, pokazuje profil i umożliwia wybór poprawnych kolumn.	Błędny plik nie zamyka aplikacji; kontrolki odświeżają się po zmianie zbioru; brak ukrytych zmiennych globalnych.
Lab. 9	Osadzenie wykresu, eksport, testy, dokumentacja i oddanie.	Pełna aplikacja, cleaned.csv, raport zmian, eksport wykresu i README.	Uruchomienie według README; przejście macierzy testów; wynik da się odtworzyć i obronić.

Kamienie milowe służą do bieżącej informacji zwrotnej. Punkty za systematyczność są przyznawane w rubryce końcowej.

Minimalna macierz testów

Przypadek	Oczekiwany rezultat	Dowód
CSV z przecinkiem i średnikiem	Dane wczytują się do poprawnej liczby kolumn.	Dwa małe pliki testowe.
Braki liczbowe i tekstowe	Wybrana strategia działa, a raport podaje liczbę zmian.	Porównanie before/after.
Duplikaty	Usuwane są tylko pełne duplikaty albo jasno wskazany klucz.	Test z kontrolowaną parą rekordów.
Wartość poza zakresem	Reguła wykrywa rekord i nie zmienia danych bez decyzji użytkownika.	Raport reguł jakości.
Stała lub nienumeryczna kolumna	Niepoprawny wykres jest blokowany z komunikatem.	Demonstracja GUI.
Eksport	CSV można ponownie wczytać, a PNG/PDF/SVG otworzyć.	Pliki wynikowe.

Kryteria oceny

Projekt jest oceniany w skali 0–100 pkt. Punkty przyznaje się na podstawie działającej wersji, kodu źródłowego, dokumentacji i krótkiej obrony.

Obszar	Maks.	Pełna punktacja	Zasady punktacji częściowej
Wczytywanie i profil danych	15	Różne separatory, kontrolowane błędy, podgląd oraz kompletny profil: rozmiar, typy, statystyki, braki, duplikaty i unikalność.	Po 2 pkt za sześć elementów profilu + 3 pkt za odporne wczytywanie i poprawne komunikaty.
Czyszczenie i ślad zmian	25	Poprawne strategie braków, duplikatów, wartości spoza zakresu i outlierów; operacje konfigurowalne; raport before/after i reset sesji.	Braki 6 pkt, duplikaty 4 pkt, reguły zakresu 4 pkt, outliery 4 pkt, raport zmian 5 pkt, reset 2 pkt.
Wizualizacje i interpretacja	15	Cztery wymagane typy, poprawny dobór zmiennych, opisy, czytelność, analiza korelacji i poprawna interpretacja.	Do 3 pkt za każdy typ wykresu; 2 pkt za korelację; 1 pkt za jakość opisów.
GUI i eksport	15	Spójny pełny przepływ; dynamiczne listy kolumn; wykres osadzony w oknie; zapis CSV i wykresów; stan operacji.	10–14 pkt: drobne braki UX; 5–9 pkt: główny przepływ działa częściowo; 0–4 pkt: GUI nie umożliwia analizy od początku do końca.
Architektura i jakość kodu	10	Model sesji oddzielony od GUI; małe funkcje; brak niekontrolowanych globali; kopie danych; sensowne nazwy i typowanie.	7–9 pkt: drobne sprzężenia; 4–6 pkt: działający monolit; 0–3 pkt: silne skutki uboczne lub duplikacja logiki.
Walidacja i obsługa błędów	8	Obsłużono błędny plik, puste dane, zły typ kolumny, brak wyboru, błąd zapisu i niepoprawne parametry reguły.	Po 1 pkt za każdy scenariusz + 2 pkt za komunikaty wskazujące rozwiązanie.
Testy	5	Automatyczne testy profilu/czyszczenia oraz udokumentowane testy GUI i eksportu.	3 pkt za testy logiki; 1 pkt za test GUI; 1 pkt za test ponownego odczytu eksportu.

Obszar	Maks.	Pełna punktacja	Zasady punktacji częściowej
Dokumentacja, proces i obrona	7	README, zależności, opis reguł, historia pracy, źródła; student uzasadnia strategię i wykonuje zmianę.	Dokumentacja 3 pkt, proces 2 pkt, obrona 2 pkt.
RAZEM	**100**		

Progi ocen i warunki

Punkty	Ocena
0–49	2,0
50–59	3,0
60–69	3,5
70–79	4,0
80–89	4,5
90–100	5,0

- **Warunek zaliczenia:** co najmniej 50 pkt oraz działająca, możliwa do uruchomienia wersja realizująca funkcję główną projektu.
- **Brak wersji uruchamialnej:** maksymalna ocena 2,0, jeżeli projektu nie da się ocenić mimo zastosowania instrukcji z README.
- **Samodzielność:** student musi wyjaśnić wskazany fragment kodu i wprowadzić niewielką zmianę podczas obrony; brak potwierdzenia autorstwa oznacza wstrzymanie oceny do ponownej weryfikacji.
- **Praca w parze:** wspólna może być ocena produktu, ale punkty za obronę i wkład są indywidualne; wymagany jest opis podziału pracy.
- **Biblioteki i generatory AI:** wolno z nich korzystać, ale należy je ujawnić w README, podać źródła i rozumieć wykorzystany kod.

Kod inspiracyjny

Obiekt sesji przechowuje osobno dane surowe i aktualne oraz prosty dziennik operacji. Funkcje wizualizacji zwracają Figure, dzięki czemu ten sam wykres można osadzić w Tkinter i zapisać do pliku.

Ważne: Fragment pokazuje wzorzec rozwiązania, lecz nie stanowi kompletnej aplikacji. Miejsca TODO oraz integrację z GUI należy zaprojektować samodzielnie.

```
from dataclasses import dataclass, field
from pathlib import Path
import pandas as pd
from matplotlib.figure import Figure


@dataclass
class DataSession:
    raw: pd.DataFrame
    current: pd.DataFrame = field(init=False)
    audit_log: list[str] = field(default_factory=list)

    def __post_init__(self) -> None:
        self.current = self.raw.copy(deep=True)

    @classmethod
    def from_csv(cls, path: Path) -> "DataSession":
```

```
        # sep=None korzysta z mechanizmu wykrywania separatora silnika Python.
        frame = pd.read_csv(path, sep=None, engine="python")
        if frame.empty:
            raise ValueError("Plik nie zawiera rekordów")
        return cls(frame)

    def profile(self) -> pd.DataFrame:
        return pd.DataFrame({
            "dtype": self.current.dtypes.astype(str),
            "missing": self.current.isna().sum(),
            "missing_pct": self.current.isna().mean().mul(100).round(2),
            "unique": self.current.nunique(dropna=True),
        })

    def drop_exact_duplicates(self) -> int:
        before = len(self.current)
        self.current = self.current.drop_duplicates().copy()
        removed = before - len(self.current)
        self.audit_log.append(f"Usunięto pełne duplikaty: {removed}")
        return removed

    def iqr_mask(self, column: str, factor: float = 1.5) -> pd.Series:
        values = pd.to_numeric(self.current[column], errors="coerce")
        q1, q3 = values.quantile([0.25, 0.75])
        iqr = q3 - q1
        if pd.isna(iqr) or iqr == 0:
            return pd.Series(False, index=self.current.index)
        return (values < q1 - factor * iqr) | (values > q3 + factor * iqr)

    def reset(self) -> None:
        self.current = self.raw.copy(deep=True)
        self.audit_log.append("Przywrócono dane surowe")


def histogram_figure(session: DataSession, column: str) -> Figure:
    data = pd.to_numeric(session.current[column], errors="coerce").dropna()
    if data.empty:
        raise ValueError("Wybrana kolumna nie zawiera danych liczbowych")
    fig = Figure(figsize=(7, 4), dpi=100)
    ax = fig.add_subplot()
    ax.hist(data, bins="auto", edgecolor="white")
    ax.set(title=f"Rozkład: {column}", xlabel=column, ylabel="Liczba rekordów")
    fig.tight_layout()
    return fig

# W GUI obiekt Figure można osadzić przez FigureCanvasTkAgg(fig, master=frame).
```

Co student ma doprojektować

- Dodać strategie uzupełniania braków i reguły zakresów bez modyfikowania danych surowych.
- Rozbudować audit_log o parametry, czas, liczbę rekordów przed i po oraz eksport raportu.
- Dodać scatter plot, box plot i bar plot z walidacją typów kolumn.
- Osadzić Figure w GUI przez FigureCanvasTkAgg i poprawnie usuwać poprzedni canvas.
- Napisać testy na małych, ręcznie kontrolowanych DataFrame, a nie tylko na dużym zbiorze referencyjnym.

Pakiet do oddania

- Kod źródłowy w uporządkowanej strukturze katalogów, bez środowiska wirtualnego i dużych plików binarnych.
- README.md: cel, wymagania, instalacja, uruchomienie, obsługiwane funkcje, znane ograniczenia i autorzy.
- Plik requirements.txt lub pyproject.toml z zależnościami.
- Co najmniej trzy reprezentatywne dane testowe oraz opis oczekiwanego wyniku.
- Krótki raport testów i lista wykorzystanych źródeł, bibliotek oraz narzędzi AI.
- Historia pracy w repozytorium Git albo równoważny dziennik zmian.
- Plik cleaned.csv, przykładowy raport zmian oraz co najmniej dwa wyeksportowane wykresy.

Materiały techniczne

Poniższe oficjalne dokumentacje są punktem odniesienia; student może dobrać inne biblioteki, jeśli uzasadni wybór i zachowa wymagania projektu.

1. **pandas.read_csv** — parametry wczytywania plików tekstowych i obsługa braków
   https://pandas.pydata.org/docs/reference/api/pandas.read_csv.html
2. **Pandas User Guide** — braki danych, duplikaty, operacje na DataFrame
   https://pandas.pydata.org/docs/user_guide/index.html
3. **Matplotlib: Embed in Tk** — osadzanie FigureCanvasTkAgg w Tkinter
   https://matplotlib.org/stable/gallery/user_interfaces/embedding_in_tk_sgskip.html
4. **Seaborn tutorial** — wykresy relacji, rozkładów i danych kategorialnych
   https://seaborn.pydata.org/tutorial.html

Arkusz oceny

Student/ka lub zespół: _____

Data obrony: _____ **Prowadzący:** _____

Kryterium	Maks.	Przyznano	Komentarz
Wczytywanie i profil danych	15		
Czyszczenie i ślad zmian	25		
Wizualizacje i interpretacja	15		
GUI i eksport	15		
Architektura i jakość kodu	10		
Walidacja i obsługa błędów	8		
Testy	5		
Dokumentacja, proces i obrona	7		
RAZEM	100		

Ocena: _____ Podpis: _____

Uwagi do poprawy / uzasadnienie oceny:

_____

_____

_____

_____

_____